

胡诗阳



扫码查看作品集

AI Agent / AI 应用开发工程师 (Java / Python 方向)

上海 · 17770029170 · hututu001@proton.me

github.com/hsy991008 · 意向：上海 / 广州 / 深圳

在线作品集：hsy991008.github.io · 三个项目的架构、运行证据与评测结果

个人简介

4 年后端开发经验，1 年 AI 应用开发经验，Java/Python 双栈，聚焦 AI Agent 在业务系统中的可靠落地。先后完成存量 Java 系统 AI 接入、机票退改资金安全助手和混合式行程恢复 Agent。擅长将模型理解与确定性规则、授权状态机和可靠执行结合，并通过真实轨迹归因、受控对照和独立盲测验证改进。

代表成果

- 企业交付：在约 4 人跨职能团队中负责后端主体，主导/参与路演排期、招聘、签到、信息机器人、上市公司数据与服务统计系统，服务多家券商、数千用户和百万级记录。
- Agent 工程：将高风险流程拆为模型理解、系统编译、Verifier 复核、用户确认、Outbox 执行与 UNKNOWN 对账；确定性错误由后端处理，开放问题再交回模型。
- 评测成果：旧题受控对照中，规划达标率由 73.4% 提升至 94.6%，模型费用降低约 34%；另以 24 道独立新题开展双版本测试，改进版达标率为 77.1%，较早期版本提高 47.9 个百分点，执行专项 6/6。

核心技能

Agent 架构：混合式 Agent Runtime、GoalIR/TravelGraph/Pareto Top-K/ActionDAG 计划编译、结构级修复、Plan-Execute、自研 Agent Loop、Tool/Function Calling、MCP、LangChain (路演/退改场景原型验证，正式主链路未采用)、了解 LangGraph。

安全与正确性：PreToolPolicy、Verifier、Proposal、数据库事务/CAS、Transactional Outbox、幂等、租约接管、UNKNOWN 对账与局部重规划。

RAG 与模型工程：BM25/向量混合检索、RRF、CrossEncoder Re-Ranking、pgvector、Elasticsearch、证据门与拒答；LoRA/SFT、训练数据构建、Prompt 降级。

评测与可观测：冻结数据集、共同驱动双臂对照、独立盲测、公开回归、真实轨迹重放与变异测试、Bad Case 分层归因、Accuracy/Latency/Cost、不可变 Trace、Langfuse。

后端工程：Java、Python、Spring Boot/Cloud、FastAPI、MyBatis、PostgreSQL、MySQL、Redis、RabbitMQ、Transactional Outbox、幂等、状态机与并发控制。

工程与前端：Qwen、DeepSeek、vLLM；Docker、Linux、Nginx、GitHub Actions；Vue3、TypeScript、Vite、SSE 状态机。

工作经历

上海略会网络科技有限公司 | Java 后端开发工程师

2023.06—2026.04

- 在约 4 人的跨职能团队中负责后端整体设计与开发，承担需求拆分、技术选型、数据库设计、Code Review 与线上故障处理，与前端、运维及项目经理协同交付。
- 从零完成智能路演排期系统后端，负责权限、排期、冲突检测、统计、数据库和 AI 接入；通过领域服务重载与数据库约束保证 AI 预约不绕过原有业务规则。
- 将档期、名额、权限与冲突不变量收敛到 Java 领域服务和 PostgreSQL 事务/约束，避免 AI 入口与普通接口并发时绕过业务终裁。
- 面向券商数字化需求，主导招聘、软硬件签到、内部信息微信机器人和上市公司数据系统，参与服务记录统计平台；相关系统服务多家券商、覆盖数千用户并处理百万级服务记录。

武汉能众科技有限公司 | 后端开发工程师

2022.03—2023.05

实习 3 个月后转正

- 参与体育用品供销存管理系统，负责库存、订单、权限、报表与商品搜索接口；使用 Spring Cloud、Redis、RabbitMQ、Elasticsearch、Nginx 与 Docker 支撑服务化、异步处理和检索。

项目经历

JourneyOps | 混合式计划 Agent 与可靠执行

2026.08—至今

Agent Runtime · Plan Compiler · Verifier · Outbox/Worker · Qwen/DeepSeek

- **场景**：面向航变后的多旅客行程恢复，联查航班、高铁、订单和退改事实；支持只退款、新目的地、方案权衡及依赖执行，使用沙箱供应商、录制交通数据和合成订单。
- **计划编译**：将自由规划演进为“模型理解与开放规划+确定性编译”；统一 GoalIR 构造与 ActionDAG 生成，模型和编译候选共用 finalizer 协调授权、重验和 Proposal 持久化。
- **资金与完成度**：模型金额作为待验证主张，编译、增强、Verifier 与装配共用权威动作资金语义；最终化前检查恢复任务的旧单处置，拦截只买不退的残缺提案。
- **信任与授权**：自动抽取和模型声明共用直接表达/转述判据；非直接要求转澄清，待授权候选不伪装通过，授权后按新 goal revision 重建重验。
- **执行与恢复**：确认时检查价格和版本漂移；Outbox/Worker 按依赖逐步执行，需要替代保障时先出票再释放原票；UNKNOWN 只沿原关联键对账，避免换键重发。
- **受控对照**：旧 31 题开展 496 次双版本运行，固定模型、Prompt 与公共驱动；规划达标率由 73.4%提升至 94.6%，全批模型费用降低约 34%。该批执行专项仍落后早期版本 2 次，单独记录不足。
- **新题验证**：24 道全新密封题、每题 2 轮双版本共 96 次运行；改进版总体达标率 77.1%，较早期版本提高 47.9 个百分点，执行专项 6/6（3 题各 2 轮）；本批双方确认前命令与安全逃逸计数均为 0。
- **验证与迭代**：先重放真实失败，区分测量与产品问题，再以通用规则、控制组和变异测试验证修复；用同场对照与独立新题评测检验效果，盲测、公开回归与工程验收分开记账。最终候选通过 2488 项测试，尚无新的端到端模型成绩。

机票退改签 Copilot | 高风险交易 AI 助手

2026.04—2026.07

Python/FastAPI · PostgreSQL · Qwen/LoRA · RAG · MCP · Langfuse · Vue3/TypeScript

- 将 LLM 限制为意图、槽位与解释层：退款金额由确定性规则引擎按航司、舱位、时间梯度和航变事实计算，金额、互斥关系与资金命令不信任模型自报。
- 用报价快照和订单锁绑定用户看到与确认的内容；确认后通过数据库事务与 Transactional Outbox 原子写入命令，唯一约束保证并发确认只有一次首次受理。
- 退款调用超时时进入 REFUND_UNKNOWN，只查原商户请求号而不换号重付；同时建设 Hybrid RAG、MCP 三源工具、SSE 状态机和 Langfuse 追踪，让“金额、证据、执行”可分层审计。
- 实现 LoRA/Prompt 双通道与模型身份门禁，防止 Prompt 模型在 LoRA 故障时替考；客规 Hybrid RAG 在已知回归集 Recall@3 为 30/30，明确不将其冒充为未知问题泛化成绩。
- 完成 176/176 确定性回归、30/30 金额 Gold、31/31 多轮剧本、22/22 对抗与 29/29 前端状态机测试，将金额、RAG、对话、安全与前端失败分开记分。

智能路演排期系统

2023.06—2026.04 / 2026.07

Java 21/Spring Boot · Python/FastAPI · PostgreSQL/pgvector · Redis · Vue3/TypeScript · Langfuse

- 从零负责路演系统后端；将 Python Agent 定位为理解与草案层，不提供下单工具，只能产生 Proposal。
- 用户确认时由 Java 唯一写入口重新校验归属、权限、状态和档期，PostgreSQL 排他约束负责并发终裁；证明在不推翻领域系统的前提下接入 AI。
- 构建研报 Hybrid RAG（向量+BM25→RRF→CrossEncoder）、ChatBI Text2SQL 三闸门、会话/Token 预算和 Langfuse Trace；专项验证对抗 18/18、ChatBI 12/12、RAG Recall@3 56/56，两种 Agent 模式 E2E 均 11/13。

教育经历

江西理工大学 | 电子信息工程 | 本科

2018—2022

说明：作品集运行环境使用沙箱供应商、录制交通数据与合成订单，不包含公司源代码、客户数据或真实供应商凭证。