

胡诗阳

AI Agent / AI应用开发工程师 (Java / Python方向)

上海 · 17770029170 · hututu001@proton.me · github.com/hsy991008 · 意向：上海 / 广州 / 深圳



扫码查看作品集

在线作品集：hsy991008.github.io · 三个项目的架构、演示与评测证据

个人简介

4年后端开发经验，Java/Python双栈，聚焦高风险业务中的AI Agent工程化。主导/独立完成三套递进式AI应用：存量Java业务AI接入、机票退改签资金安全助手、可验证可恢复的混合式计划级Agent，累计约7.6万行工程代码（不含文档、数据与模型权重）。坚持“LLM提议、系统裁决”，将权限、金额、幂等和执行收敛到Policy/Verifier、数据库事务与状态机，并通过冻结题集、回归测试和可复算Trace验证效果，具备从模型接入、业务编排到安全执行和评测交付的完整能力。

代表成果

- 企业交付：在约4人跨职能团队中负责后端主体，主导/参与路演排期、招聘、签到、信息机器人、上市公司数据与服务统计系统，服务多家券商、数千用户和百万级记录。
- 混合式Agent：自研受控Agent Runtime (Harness)，按Observe→Decide→Verify→Act/Reconcile→Replan循环；明确约束与常见结构由后端兜底，开放方案交给模型，Policy/Verifier掌握执行权。
- 评测闭环：完成DeepSeek/Qwen控制/处理四个31×8窗口（992次）；提前收尾12/8→0、平均轮数均降至2.92、安全逃逸0；主增益+7.1/+3.3pp未达预注册+12pp，未推广全开配置。

核心技能

Agent架构：混合式Agent Runtime (Observe-Plan-Verify-Act/Reconcile-Replan)、结构级修复/后端骨架、Plan-Execute、自研Agent Loop、Tool/Function Calling、MCP、LangChain (Demo)、了解LangGraph。

安全与正确性：PreToolPolicy、Verifier、Proposal、数据库事务/CAS、Transactional Outbox、幂等、租约接管、UNKNOWN对账与局部重规划。

RAG与模型工程：BM25/向量混合检索、RRF、CrossEncoder Re-Ranking、pgvector、Elasticsearch、证据门与拒答；LoRA/SFT、训练数据构建、Prompt降级。

评测与可观测：Golden Dataset、Regression Test、Benchmark、Bad Case归因、Accuracy/Latency/Cost指标、不可变Trace、Langfuse、评测看板。

后端工程：Java、Python、Spring Boot/Cloud、FastAPI、MyBatis、PostgreSQL、MySQL、Redis、RabbitMQ、Transactional Outbox、幂等、状态机与并发控制。

工程与前端：Qwen、DeepSeek、vLLM；Docker、Linux、Nginx、GitHub Actions；Vue3、TypeScript、Vite、SSE状态机。

工作经历

上海略会网络科技有限公司 | Java后端开发工程师

2023.06-2026.04

- 在约4人的跨职能团队中负责后端整体设计与开发，承担需求拆分、技术选型、数据库设计、Code Review与线上故障处理，与前端、运维及项目经理协同交付。
- 从零完成智能路演排期系统后端，负责权限、排期、冲突检测、统计、数据库和AI接入；通过领域服务重载与数据库约束保证AI预约不绕过原有业务规则。
- 将档期、名额、权限与冲突不变量收敛到Java领域服务和PostgreSQL事务/约束，避免AI入口与普通接口并发时绕过业务终裁。
- 面向券商数字化需求，主导招聘、软硬件签到、内部信息微信机器人和上市公司数据系统，参与服务记录统计平台；相关系统服务多家券商、覆盖数千用户并处理百万级服务记录。

武汉能众科技有限公司 | 后端开发工程师

2022.03-2023.05

实习3个月转正

- 参与体育用品供销管理系统，负责库存、订单、权限、报表与商品搜索接口；使用Spring Cloud、Redis、RabbitMQ、Elasticsearch、Nginx与Docker支撑服务化、异步处理和检索。

项目经历

JourneyOps | 混合式计划级Agent与故障恢复2026.08-至今

Agent Runtime · Repair Protocol · Verifier · Outbox/Worker · Qwen/DeepSeek

- 面向航班取消/延误后的行程恢复：用户用自然语言给出到达时间、预算和换乘偏好，系统联查航班、高铁、接驳、改签、退票与订单事实，生成“先锁定替代资源，再释放原票”的多步恢复方案。
- 自研可验证、可恢复的Agent Runtime (Harness)：每轮从权威状态重建上下文，模型提出工具或Candidate Plan；后端负责证据准备、六类错误分层、计划骨架、用户确认、执行对账与停止条件。
- 落实“计划级提议、系统级裁决”：Schema不提供金额、幂等键、用户确认或执行身份；后端从权威台账派生预计退款、新增支出、净成本与垫资峰值，高风险权限在结构上不可表达；双订单退款使用独立幂等键。
- PreToolPolicy在工具前检查风险、订单归属与行程范围；Verifier用权威订单、支付、报价、库存和授权重算候选，通过后才生成Proposal。确认时价格或版本漂移则作废，保持供应商调用为0。
- 将不可逆动作按依赖逐步入箱：确认后只创建首个取得命令，替代资源出票成功前，退款命令在数据库中根本不存在；崩溃重启后仍可按持久化依赖继续。
- 供应商调用已发出但结果不明时进入UNKNOWN，禁止换键重发，只用原幂等键对账；通过send_started_at分隔“确定未发送”与“可能已发送”，配合租约接管、条件更新和局部重规划恢复。
- 建立31题冻结考场、scorer-v3、配置指纹、不可变Trace与变异测试；M3完成992次正式双窗口，平均轮数4.41/4.73→2.92、提前收尾12/8→0、安全逃逸0；增益未达+12pp即拒绝推广。
- 双模型0/16且Skill A/B无稳定收益后，停止堆Prompt，改由后端按权威证据生成双订单替代链骨架并重过完整Verifier；触发后9/9执行到COMPLETED，确认前命令始终为0。

机票退改签Copilot | 高风险交易AI助手个人项目2026.04-2026.07

Python/FastAPI · PostgreSQL · Qwen/LoRA · RAG · MCP · Langfuse · Vue3/TypeScript

- 将LLM限制为意图、槽位与解释层：退款金额由确定性规则引擎按航司、舱位、时间梯度和航变事实计算，金额、互斥关系与资金命令不信任模型自报。
- 用报价快照和订单锁绑定用户看到与确认的内容；确认后通过数据库事务与Transactional Outbox原子写入命令，唯一约束保证并发确认只有一次首次受理。
- 退款调用超时进入REFUND_UNKNOWN，只查原商户请求号而不换号重付；同时建设Hybrid RAG、MCP三源工具、SSE状态机和Langfuse追踪，让“金额、证据、执行”可分层审计。
- 实现LoRA/Prompt双通道与模型身份门禁，防止Prompt模型在LoRA故障时替考；客规Hybrid RAG在已知回归集Recall@3为30/30，明确不将其冒充为未知问题泛化成绩。
- 完成176/176确定性回归、30/30金额Gold、31/31多轮剧本、22/22对抗与29/29前端状态机测试，将金额、RAG、对话、安全与前端失败分开记分。

智能路演排期系统 | 公司项目 / 离职后独立重构演示版2023.06-2026.04 / 2026.07

Java 21/Spring Boot · Python/FastAPI · PostgreSQL/pgvector · Redis · Vue3/TypeScript · Langfuse

- 任职期间从零负责公司路演系统后端；独立重构版将Python Agent定位为理解与草案层，不提供下单工具，只能产生Proposal。
- 用户确认时由Java唯一写入口重新校验归属、权限、状态和档期，PostgreSQL排他约束负责并发终裁；证明在不推翻领域系统的前提下接入AI。
- 构建研报Hybrid RAG（向量+BM25→RRF→CrossEncoder）、ChatBI Text2SQL三闸门、会话/Token预算和Langfuse Trace；重构版验证对抗18/18、ChatBI 12/12、RAG Recall@3 56/56，两种Agent模式E2E均11/13。

教育经历

江西理工大学 | 电子信息工程 | 本科2018-2022

说明：个人项目使用沙箱供应商、录制交通数据和合成订单；公司项目展示仓库为离职后独立重构，不包含公司源代码或客户数据。