

胡诗阳

AI Agent / AI 应用开发工程师 (Java / Python 方向)

上海 · 17770029170 · hututu001@proton.me ·
github.com/hsy991008 · 意向：上海 / 广州 / 深圳



扫码查看作品集

在线作品集：hsy991008.github.io · 三个项目的架构、运行证据与评测结果

个人简介

4 年后端开发经验，Java/Python 双栈，聚焦高风险业务中的 AI Agent 工程化。先后完成存量 Java 系统 AI 接入、机票退改签资金安全助手与混合式行程恢复 Agent，累计约 7.6 万行工程代码（不含文档、数据与模型权重）。擅长把模型的语言理解与后端规则、交易和状态机结合：模型负责理解歧义和开放目标，系统负责编译可执行计划、核验权威事实并可靠执行；能够独立完成架构、实现、评测与交付。

代表成果

- 企业交付：在约 4 人跨职能团队中负责后端主体，主导/参与路演排期、招聘、签到、信息机器人、上市公司数据与服务统计系统，服务多家券商、数千用户和百万级记录。
- Agent 工程：将高风险流程拆为模型理解、系统编译、Verifier 复核、用户确认、Outbox 执行与 UNKNOWN 对账；确定性错误由后端处理，开放问题再交回模型。
- 受控评测：同一 DeepSeek Flash、Prompt、旧 31 题与共同驱动下完成 496 次双臂配对；当前版规划 135/184→174/184，成本降低 34%，P50 延迟降低 73%，安全逃逸保持 0。

核心技能

Agent 架构：混合式 Agent Runtime、GoalIR/TravelGraph/Pareto Top-K/ActionDAG 计划编译、结构级修复、Plan-Execute、自研 Agent Loop、Tool/Function Calling、MCP、LangChain（路演/退改场景原型验证，正式主链路未采用）、了解 LangGraph。

安全与正确性：PreToolPolicy、Verifier、Proposal、数据库事务/CAS、Transactional Outbox、幂等、租约接管、UNKNOWN 对账与局部重规划。

RAG 与模型工程：BM25/向量混合检索、RRF、CrossEncoder Re-Ranking、pgvector、Elasticsearch、证据门与拒答；LoRA/SFT、训练数据构建、Prompt 降级。

评测与可观测：Golden Dataset、Regression Test、Benchmark、Bad Case 归因、Accuracy/Latency/Cost 指标、不可变 Trace、Langfuse、评测看板。

后端工程：Java、Python、Spring Boot/Cloud、FastAPI、MyBatis、PostgreSQL、MySQL、Redis、RabbitMQ、Transactional Outbox、幂等、状态机与并发控制。

工程与前端：Qwen、DeepSeek、vLLM；Docker、Linux、Nginx、GitHub Actions；Vue3、TypeScript、Vite、SSE 状态机。

工作经历

上海略会网络科技有限公司 | Java 后端开发工程师

2023.06—2026.04

- 在约 4 人的跨职能团队中负责后端整体设计与开发，承担需求拆分、技术选型、数据库设计、Code Review 与线上故障处理，与前端、运维及项目经理协同交付。
- 从零完成智能路演排期系统后端，负责权限、排期、冲突检测、统计、数据库和 AI 接入；通过领域服务重载与数据库约束保证 AI 预约不绕过原有业务规则。
- 将档期、名额、权限与冲突不变量收敛到 Java 领域服务和 PostgreSQL 事务/约束，避免 AI 入口与普通接口并发时绕过业务终裁。
- 面向券商数字化需求，主导招聘、软硬件签到、内部信息微信机器人和上市公司数据系统，参与服务记录统计平台；相关系统服务多家券商、覆盖数千用户并处理百万级服务记录。

武汉能众科技有限公司 | 后端开发工程师

2022.03—2023.05

实习 3 个月转正

- 参与体育用品供销存管理系统，负责库存、订单、权限、报表与商品搜索接口；使用 Spring Cloud、Redis、RabbitMQ、Elasticsearch、Nginx 与 Docker 支撑服务化、异步处理和检索。

项目经历

JourneyOps | 混合式计划级 Agent 与故障恢复

2026.08—至今

Agent Runtime · Plan Compiler · Verifier · Outbox/Worker · Qwen/DeepSeek

- 场景：面向航班取消/延误后的行程恢复；用户给出到达时间、预算和换乘偏好，系统联查航班、高铁、接驳、改签、退票与订单事实，生成“先锁定替代资源，再释放原票”的多步方案。
- 运行时：每轮从权威状态重建上下文；模型处理歧义与开放残差，计划编译器将 GoalIR 和权威交通事实编译为候选或不可行证明。
- 权限与资金：Schema 不提供金额、幂等键、用户确认或执行身份；后端从权威台账派生预计退款、新增支出、净成本与垫资峰值，高风险权限在结构上不可表达。
- 裁决：PreToolPolicy 在工具前检查风险、订单归属与行程范围；Verifier 用订单、支付、报价、库存和授权重算候选，通过后才生成 Proposal，价格或版本漂移则作废。
- 执行：不可逆动作按依赖逐步入箱；确认后只创建首个取得命令，替代资源出票成功前，退款命令在数据库中尚不存在，崩溃重启后可继续。
- 恢复：供应商调用结果不明时进入 UNKNOWN，禁止换键重发，只用原关联键对账；send_started_at 区分“确定未发送”与“可能已发送”。
- 评测：496 次同模型、同 Prompt、同题、共同驱动配对中，规划 135/184→174/184，综合 168/248→209/248；成本降低 34%，P50 延迟 5.17s→1.39s，安全逃逸 0→0。
- 边界：执行专项 15/32→13/32 仍需验证；成绩证明旧 31 题回归集上的受控优势，新题泛化待独立盲测；系统仅使用沙箱供应商、录制交通数据和合成订单。

机票退改签 Copilot | 高风险交易 AI 助手

2026.04—2026.07

Python/FastAPI · PostgreSQL · Qwen/LoRA · RAG · MCP · Langfuse · Vue3/TypeScript

- 将 LLM 限制为意图、槽位与解释层：退款金额由确定性规则引擎按航司、舱位、时间梯度和航变事实计算，金额、互斥关系与资金命令不信任模型自报。
- 用报价快照和订单锁绑定用户看到与确认的内容；确认后通过数据库事务与 Transactional Outbox 原子写入命令，唯一约束保证并发确认只有一次首次受理。
- 退款调用超时时进入 REFUND_UNKNOWN，只查原商户请求号而不换号重付；同时建设 Hybrid RAG、MCP 三源工具、SSE 状态机和 Langfuse 追踪，让“金额、证据、执行”可分层审计。
- 实现 LoRA/Prompt 双通道与模型身份门禁，防止 Prompt 模型在 LoRA 故障时替考；客规 Hybrid RAG 在已知回归集 Recall@3 为 30/30，明确不将其冒充为未知问题泛化成绩。
- 完成 176/176 确定性回归、30/30 金额 Gold、31/31 多轮剧本、22/22 对抗与 29/29 前端状态机测试，将金额、RAG、对话、安全与前端失败分开记分。

智能路演排期系统

2023.06—2026.04 / 2026.07

Java 21/Spring Boot · Python/FastAPI · PostgreSQL/pgvector · Redis · Vue3/TypeScript · Langfuse

- 从零负责路演系统后端；将 Python Agent 定位为理解与草案层，不提供下单工具，只能产生 Proposal。
- 用户确认时由 Java 唯一写入口重新校验归属、权限、状态和档期，PostgreSQL 排他约束负责并发终裁；证明在不推翻领域系统的前提下接入 AI。
- 构建研报 Hybrid RAG (向量+BM25→RRF→CrossEncoder)、ChatBI Text2SQL 三闸门、会话/Token 预算和 Langfuse Trace；专项验证对抗 18/18、ChatBI 12/12、RAG Recall@3 56/56，两种 Agent 模式 E2E 均 11/13。

教育经历

江西理工大学 | 电子信息工程 | 本科

2018—2022

说明：作品集运行环境使用沙箱供应商、录制交通数据与合成订单，不包含公司源代码、客户数据或真实供应商凭证。