

胡诗阳



扫码查看作品集

AI Agent / AI 应用开发工程师 (Java / Python 方向)

上海 · 17770029170 · hututu001@proton.me

github.com/hsy991008 · 意向：上海 / 广州 / 深圳

在线作品集：hsy991008.github.io · 三个项目的架构、运行证据与评测结果

个人简介

4 年后端开发经验，1 年 AI 应用开发经验，Java/Python 双栈，聚焦 AI Agent 在业务系统中的可靠落地。先后完成存量 Java 系统 AI 接入、机票退改资金安全助手和混合式行程恢复 Agent。擅长将模型理解与确定性规则、授权状态机和可靠执行结合，并通过真实轨迹归因、受控对照和独立盲测验证改进。

代表成果

- 企业交付：在约 4 人团队中负责后端主体，相关系统服务多家券商、数千用户并处理百万级记录。
- Agent 工程：完成业务接入、资金安全与计划级控制三阶段实践，形成“模型理解、系统裁决、可靠执行”的统一方法。
- 评测成果：旧题受控对照中，规划达标率由 73.4% 提升至 94.6%，模型费用降低约 34%；另以 24 道独立新题开展双版本测试，改进版达标率为 77.1%，较早期版本提高 47.9 个百分点，执行专项 6/6。

核心技能

Agent 与 LLM：混合式 Agent Runtime、计划编译与结构级修复、Plan-Execute、自研 Agent Loop、Tool/Function Calling、MCP、LangChain (路演/退改场景原型验证，正式主链路未采用)、了解 LangGraph；Qwen、DeepSeek、vLLM。

RAG 与模型工程：BM25/向量混合检索、RRF、CrossEncoder Re-Ranking、pgvector、Elasticsearch、证据门与拒答；LoRA/SFT、训练数据构建、Prompt 降级。

评测与可观测：冻结数据集、共同驱动双臂对照、独立盲测、公开回归、真实轨迹重放与变异测试、Bad Case 分层归因、Accuracy/Latency/Cost、不可变 Trace、Langfuse。

后端工程：Java、Python、Spring Boot/Cloud、FastAPI、MyBatis、PostgreSQL、MySQL、Redis、RabbitMQ、Transactional Outbox、幂等、状态机与并发控制。

工程与前端：Docker、Linux、Nginx、GitHub Actions；Vue3、TypeScript、Vite、SSE 状态机。

工作经历

上海略会网络科技有限公司 | Java 后端开发工程师 2023.06—2026.04

- 在约 4 人的跨职能团队中负责后端整体设计与开发，承担需求拆分、技术选型、数据库设计、Code Review 与线上故障处理，与前端、运维及项目经理协同交付。
- 从零完成智能路演排期系统后端，负责权限、排期、冲突检测、统计、数据库和 AI 接入；通过领域服务重载与数据库约束保证 AI 预约不绕过原有业务规则。
- 面向券商数字化需求，主导招聘、软硬件签到、内部信息微信机器人和上市公司数据系统，参与服务记录统计平台；相关系统服务多家券商、覆盖数千用户并处理百万级服务记录。

武汉能众科技有限公司 | 后端开发工程师 2022.03—2023.05

实习 3 个月转正

- 参与体育用品供销存管理系统建设，负责库存、订单、权限、报表和商品搜索等接口的开发、更新与维护。
- 使用 Spring Boot、Spring Cloud、MyBatis、Redis、RabbitMQ 和 Elasticsearch 完成业务服务、缓存、异步消息与检索功能，配合 Nginx、Docker 维护运行环境。

项目经历

JourneyOps | 混合式行程恢复 Agent

2026.08—至今

Python · SQLite · Qwen/DeepSeek · Plan Compiler · Verifier · Outbox/Worker

- **场景与目标**：面向航班取消/延误后的多旅客行程恢复，支持退改签、新目的地与跨交通方式比较；将模型自由拼计划演进为“模型理解、后端编译校验、用户确认后执行”。
- **架构收敛**：统一 GoallR、计划编译和候选最终化入口；按权威证据校验金额与任务完成度，自动抽取和模型声明共用要求来源判据，避免转述被登记为用户硬约束。
- **可靠执行**：授权或目标版本变化后重验，确认时价格漂移作废旧方案；Outbox/Worker 按依赖执行，需要替代保障时先出票再释放原票，供应商结果不明时沿原关联键对账。
- **受控对照**：旧 31 题开展 496 次双版本运行，固定模型、Prompt 与公共驱动；规划达标率由 73.4%提升至 94.6%，全批模型费用降低约 34%。
- **新题验证**：24 道全新密封题、每题 2 轮双版本共 96 次运行；改进版总体达标率 77.1%，较早期版本提高 47.9 个百分点，执行专项 6/6 (3 题各 2 轮) ；本批双方确认前命令与安全逃逸计数均为 0。

机票退改签 Copilot | 高风险交易 AI 助手

2026.04—2026.07

Python/FastAPI · PostgreSQL · Qwen/LoRA · RAG · MCP · Langfuse · Vue3/TypeScript

- 设计“LLM 提议、系统裁决”：模型负责意图、槽位与解释，退款金额由规则引擎按航司、舱位、时间梯度和航变事实计算，模型输出无法直接改变资金结果。
- 构建报价快照、订单锁、Transactional Outbox、固定商户请求号与 REFUND_UNKNOWN 对账；外部超时后只查询原请求，并通过数据库约束保证并发确认恰好一次首次受理。
- 建设 LoRA/Prompt 双通道、Hybrid RAG、MCP 工具、SSE 状态机、运营台和 Langfuse；模型身份门禁防止 Prompt 替 LoRA 考试。完成 176/176 确定性回归、31/31 多轮剧本、22/22 对抗和 29/29 前端测试。

智能路演排期系统

2023.06—2026.04 / 2026.07

Java 21/Spring Boot · Python/FastAPI · PostgreSQL/pgvector · Redis · Vue3/TypeScript · Langfuse

- 从零负责路演系统后端，并以 Python Agent 作为理解与草案层接入存量 Java 业务，形成“AI 生成 Proposal、Java 确认终裁”的完整链路。
- 模型没有下单工具，只能创建 Proposal 草案；Java 在用户确认时重新校验归属、权限、状态和档期，PostgreSQL 排他约束负责并发终裁。
- 构建研报 Hybrid RAG (向量+BM25→RRF→CrossEncoder)、ChatBI Text2SQL 三闸门、服务端会话与 Token 预算，并通过 Langfuse 记录模型、工具、RAG 和护栏 Trace。
- 专项验证：对抗 18/18、ChatBI 12/12、RAG Recall@3 56/56；native/orchestrated 两种 Agent 模式 E2E 均为 11/13，失败集中在本地显存争用导致的 RAG 超时。

教育经历

江西理工大学 | 电子信息工程 | 本科

2018—2022

说明：作品集运行环境使用沙箱供应商、录制交通数据与合成订单，不包含公司源代码、客户数据或真实供应商凭证。