

胡诗阳

AI Agent / AI 应用开发工程师 (Java / Python 方向)

上海 · 17770029170 · hututu001@proton.me · github.com/hsy991008 · 意向：上海 / 广州 / 深圳

在线作品集：hsy991008.github.io · 三个项目的架构、运行证据与评测结果

个人简介

4 年后端开发经验，Java/Python 双栈，聚焦高风险业务中的 AI Agent 落地。完成存量 Java 系统 AI 接入、机票退改资金安全助手和混合式行程恢复 Agent。擅长把模型理解与后端规则结合：模型处理自然语言和开放问题，系统负责计划生成、权威校验、用户确认与可靠执行；能够独立完成架构、实现、评测和交付。

代表成果

- 企业交付：在约 4 人团队中负责后端主体，相关系统服务多家券商、数千用户并处理百万级记录。
- Agent 工程：完成业务接入、资金安全与计划级控制三阶段实践，形成“模型理解、系统裁决、可靠执行”的统一方法。
- 受控评测：同一 DeepSeek Flash、Prompt、旧 31 题与共同驱动下完成 496 次双臂配对；当前版规划 135/184→174/184，成本降低 34%，P50 延迟降低 73%，安全逃逸保持 0。

核心技能

Agent 与 LLM：混合式 Agent Runtime、计划编译与结构级修复、Plan-Execute、自研 Agent Loop、Tool/Function Calling、MCP、LangChain (路演/退改场景原型验证，正式主链路未采用)、了解 LangGraph；Qwen、DeepSeek、vLLM。

RAG 与模型工程：BM25/向量混合检索、RRF、CrossEncoder Re-Ranking、pgvector、Elasticsearch、证据门与拒答；LoRA/SFT、训练数据构建、Prompt 降级。

评测与可观测：Golden Dataset、Regression Test、Benchmark、Bad Case 归因、Accuracy/Latency/Cost 指标、不可变 Trace、Langfuse、评测看板。

后端工程：Java、Python、Spring Boot/Cloud、FastAPI、MyBatis、PostgreSQL、MySQL、Redis、RabbitMQ、Transactional Outbox、幂等、状态机与并发控制。

工程与前端：Docker、Linux、Nginx、GitHub Actions；Vue3、TypeScript、Vite、SSE 状态机。

工作经历

上海略会网络科技有限公司 | Java 后端开发工程师 2023.06—2026.04

- 在约 4 人的跨职能团队中负责后端整体设计与开发，承担需求拆分、技术选型、数据库设计、Code Review 与线上故障处理，与前端、运维及项目经理协同交付。
- 从零完成智能路演排期系统后端，负责权限、排期、冲突检测、统计、数据库和 AI 接入；通过领域服务重载与数据库约束保证 AI 预约不绕过原有业务规则。
- 面向券商数字化需求，主导招聘、软硬件签到、内部信息微信机器人和上市公司数据系统，参与服务记录统计平台；相关系统服务多家券商、覆盖数千用户并处理百万级服务记录。

武汉能众科技有限公司 | 后端开发工程师 2022.03—2023.05

实习 3 个月后转正

- 参与体育用品供销存管理系统建设，负责库存、订单、权限、报表和商品搜索等接口的开发、更新与维护。
- 使用 Spring Boot、Spring Cloud、MyBatis、Redis、RabbitMQ 和 Elasticsearch 完成业务服务、缓存、异步消息与检索功能，配合 Nginx、Docker 维护运行环境。

项目经历

JourneyOps | 混合式计划级 Agent

2026.08—至今

Python · SQLite · Qwen/DeepSeek · Plan Compiler · Verifier · Outbox/Worker

- 场景：面向航变后的行程恢复；用户只需说明到达时间、目的地、预算和换乘偏好，系统联查航班、高铁、接驳、订单与退改规则，生成“先锁定替代资源，再释放原票”的方案。
- 架构：模型负责理解、澄清与解释；后端将明确目标和权威事实编译为候选方案或不可行证明，所有候选仍须通过 Verifier，确认后才进入 Outbox/Worker。
- 可靠执行：价格或版本漂移会作废旧方案；出票结果不明时沿用原关联键对账；替代资源确认前，退款命令在数据库中尚不存在。
- 效果：496 次同模型、同 Prompt、同题、共同驱动配对中，规划 135/184→174/184，综合 168/248→209/248；成本降低 34%，P50 延迟 5.17s→1.39s，安全逃逸 0→0。边界：执行专项 15/32→13/32，新题泛化待独立盲测。

机票退改签 Copilot | 高风险交易 AI 助手

2026.04—2026.07

Python/FastAPI · PostgreSQL · Qwen/LoRA · RAG · MCP · Langfuse · Vue3/TypeScript

- 设计“LLM 提议、系统裁决”：模型负责意图、槽位与解释，退款金额由规则引擎按航司、舱位、时间梯度和航变事实计算，模型输出无法直接改变资金结果。
- 构建报价快照、订单锁、Transactional Outbox、固定商户请求号与 REFUND_UNKNOWN 对账；外部超时后只查询原请求，并通过数据库约束保证并发确认恰好一次首次受理。
- 建设 LoRA/Prompt 双通道、Hybrid RAG、MCP 工具、SSE 状态机、运营台和 Langfuse；模型身份门禁防止 Prompt 替 LoRA 考试。完成 176/176 确定性回归、31/31 多轮剧本、22/22 对抗和 29/29 前端测试。

智能路演排期系统

2023.06—2026.04 / 2026.07

Java 21/Spring Boot · Python/FastAPI · PostgreSQL/pgvector · Redis · Vue3/TypeScript · Langfuse

- 从零负责路演系统后端，并以 Python Agent 作为理解与草案层接入存量 Java 业务，形成“AI 生成 Proposal、Java 确认终裁”的完整链路。
- 模型没有下单工具，只能创建 Proposal 草案；Java 在用户确认时重新校验归属、权限、状态和档期，PostgreSQL 排他约束负责并发终裁。
- 构建研报 Hybrid RAG (向量+BM25→RRF→CrossEncoder)、ChatBI Text2SQL 三闸门、服务端会话与 Token 预算，并通过 Langfuse 记录模型、工具、RAG 和护栏 Trace。
- 专项验证：对抗 18/18、ChatBI 12/12、RAG Recall@3 56/56；native/orchestrated 两种 Agent 模式 E2E 均为 11/13，失败集中在本地显存争用导致的 RAG 超时。

教育经历

江西理工大学 | 电子信息工程 | 本科

2018—2022

说明：作品集运行环境使用沙箱供应商、录制交通数据与合成订单，不包含公司源代码、客户数据或真实供应商凭证。